

ИССЛЕДОВАТЕЛЬСКАЯ РАБОТА

Устойчивое моделирование на синтетическом multilabel-датасете

Стратегия выбора модели при наличии публичной и скрытой тестовых выборок

Параметр	Описание
Объект	CI Case Championship: прогноз интереса клиента к 9 банковским продуктам
Данные	70 000 наблюдений, 8 признаков, 9 бинарных таргетов
Метрика	Pooled / micro ROC-AUC
Метод	EDA, repeated out-of-fold validation, ablation, calibration и blending

Case study по данным и локальным решениям проекта

Москва, 2026

Аннотация

Исследуется задача multilabel-классификации, в которой для каждого клиента требуется оценить вероятность интереса к девяти банковским продуктам. Особенность соревнования — наличие публичной и скрытой частей тестовой выборки при близких значениях leaderboard-score у участников. Цель работы — определить, связана ли такая близость с ограниченным сигналом данных, выбрать модель с наилучшим ожидаемым обобщением и оценить целесообразность подгонки под публичную часть лидерборда.

Анализ 70 000 обучающих наблюдений выявил признаки искусственной генерации: отсутствие пропусков и дублей, почти независимые базовые признаки, одинаковую частоту положительного класса для девяти экономически различных продуктов и отдельные бизнес-неправдоподобные комбинации. Сравнение линейных, нелинейных и ансамблевых методов показало, что регуляризованная логистическая регрессия устойчиво превосходит более сложные модели по pooled/micro ROC-AUC. Repeated OOF-оценка для лучшей конфигурации составила 0.670327 со стандартным отклонением 0.000018. Улучшения от blending и дополнительной калибровки не превысили нескольких миллионных AUC и не являются практически значимыми.

Основной результат. Для hidden private рекомендуется простой ordinal logistic regression на всех восьми признаках. Выбор по public leaderboard при различиях менее 0.001–0.002 создает более высокий риск переобучения, чем ожидаемую пользу.

Ключевые слова: *multilabel classification, synthetic data, logistic regression, ROC-AUC, out-of-fold validation, leaderboard overfitting, private test.*

1. Введение

Соревнования с публичным лидербордом создают двойную задачу. Участник должен построить предиктивную модель и одновременно не переобучить процесс выбора модели на ограниченную публичную часть теста. Чем меньше различия между кандидатами и чем больше число сабмитов, тем выше вероятность выбрать конфигурацию, которая случайно удачна на public, но хуже обобщается на hidden private.

В рассматриваемом кейсе большинство участников имеет близкий score. Это может означать как реальный предел качества, задаваемый слабым сигналом, так и наличие общей простой структуры генератора, которую одинаково восстанавливают разные решения. Для ответа нужны не отдельные leaderboard-наблюдения, а воспроизводимый локальный протокол.

1.1. Исследовательские вопросы

1. Какие свойства датасета определяют достижимое качество и выбор класса моделей?
2. Какая стратегия надежнее: максимизация public score или выбор по repeated OOF?
3. Можно ли восстановить hidden private выборку или ее распределение из локальных материалов?

1.2. Вклад работы

- Проведен аудит качества и правдоподобия данных.
- Сравнены линейные, нелинейные и long-format постановки.
- Проверена устойчивость результатов на пяти seed.
- Оценен масштаб шума public leaderboard относительно различий между моделями.
- Сформулирована стратегия выбора основного и резервного финальных сабмитов.

2. Постановка задачи и данные

Пусть x_i — вектор из восьми признаков клиента, а $y_i \in \{0,1\}^9$ — вектор интереса к девяти продуктам. Модель строит $p_i = f(x_i)$, где каждый компонент p_{ij} является оценкой вероятности положительного класса для пары «клиент–продукт».

В локальном решении метрика определена как pooled/micro ROC-AUC: все 630 000 пар «клиент–продукт» рассматриваются совместно. В вероятностной интерпретации AUC оценивает $P(p^+ > p^-)$, поэтому важна не только сортировка внутри отдельного продукта, но и согласованность шкал между продуктами.

Таблица 1. Базовая инвентаризация датасета

Характеристика	Значение
Число наблюдений	70 000
Число признаков	8
Число таргетов	9
Пропуски	0
Дубли user_id	0
Дубли строк признаков	0
Формат user_id	Уникальная 10-символьная hex-строка

Источник: train_weRmhWx.csv; расчеты авторского анализа.

3. Диагностика синтетической природы данных

Совокупность статистических и предметных признаков указывает на искусственную генерацию. По отдельности каждый признак не является доказательством, но их совместное появление маловероятно для реального банковского портфеля.

Таблица 2. Признаки искусственной генерации

Наблюдение	Интерпретация
Идеальная чистота	Нет пропусков, дублей и ошибок типов.
Независимость признаков	Максимальная заметная корреляция между признаками около 0.0105.
Баланс таргетов	Все девять положительных классов находятся примерно в диапазоне 48.96 – 49.94%.
Нереалистичная согласованность	У 10.20% клиентов tenure_months превышает число месяцев после 18 лет.
Случайный идентификатор	user_id уникален и не демонстрирует содержательной структуры.
Дискретный float	tx_count_30d хранится как float, но 100% значений целые.

Источник: train_weRmhWx.csv; EDA из data_research_report.md.




Рисунок 1. Доля положительного класса по продуктам

Источник: train_weRmhWx.csv. Практически одинаковая частота экономически разных продуктов является сильным признаком синтетики.

Среднее число положительных продуктов на клиента равно 4.461 из 9. Распределение числа положительных меток близко к сумме нескольких почти независимых Bernoulli-событий с вероятностью около 0.5. После учета признаков остаточные корреляции между продуктами снижаются примерно до $|corr| < 0.007$, что ограничивает потенциал classifier chains и других методов моделирования label dependency.

4. Методология экспериментов

4.1. Протокол валидации

Основной протокол — 5-fold out-of-fold оценка отдельно для каждого бинарного таргета с последующим объединением прогнозов в матрицу $70\,000 \times 9$. Для оценки устойчивости эксперимент повторялся на seed 7, 13, 42, 123 и 2026. Выбор модели выполнялся по pooled/micro ROC-AUC; macro и per-product AUC использовались как диагностические метрики.

Критерий практической значимости. Микроулучшения менее 0.0005 AUC трактуются как эквивалентность моделей, если они не повторяются устойчиво на разных seed и не превышают неопределенность public leaderboard.

4.2. Проверенные семейства моделей

Группа	Проверенные варианты
Линейные	LogisticRegression; C=0.003...30; balanced/unbalanced; ordinal/one-hot.
Ablation	Все признаки; четыре сильных; четыре слабых.
Нелинейные	PolynomialFeatures degree=2; QuantileTransformer; HistGradientBoosting.
Глобальная постановка	Long-format user $\times$ product с product-specific interactions.
Постобработка	Cross-fit affine calibration между продуктами.
Ансамбли	Взвешенные blends логпера с one-hot, HGB, long-format и calibrated моделями.

Источник: Локальные Stage 2 OOF-прогоны.

5. Результаты моделирования

5.1. Сравнение кандидатов

Таблица 3. Single-seed 5-fold OOF, seed=42

Модель	Micro AUC	Macro AUC	Вывод
LogReg strong-only, C=1	0.670339	0.658281	Single-seed максимум
LogReg ordinal, C=1	0.670323	0.658390	Базовый кандидат
LogReg ordinal, C=0.03	0.670323	0.658391	Более регуляризованный
LogReg one-hot, C=1	0.670309	0.658331	Без прироста
Global long LogReg	0.670288	0.658374	Без прироста
LogReg balanced	0.670279	0.658390	Хуже micro
LogReg polynomial	0.669819	0.657802	Переобучение
HistGradientBoosting	0.669387	0.657096	Хуже линейной модели
LogReg quantile	0.666959	0.656020	Вредное преобразование
LogReg weak-only	0.503571	0.501270	Почти нет сигнала

Источник: Stage 2 controlled model search.




Рисунок 2. Сравнение OOF micro ROC-AUC

Источник: Stage 2 OOF. Ось намеренно увеличена вокруг диапазона лучших моделей; различия остаются крайне малы.

Сложность модели не приводит к улучшению. Наоборот, polynomial features, quantile transform и gradient boosting ухудшают OOF. Это согласуется с гипотезой о генерации таргетов из простых линейно-монотонных функций небольшого числа признаков.

5.2. Устойчивость на разных seed

Модель	Mean	Std	Min	Max
LogReg ordinal, C=1	0.670327	0.000018	0.670304	0.670355
LogReg ordinal, C=0.03	0.670327	0.000018	0.670304	0.670355
LogReg strong-only	0.670323	0.000013	0.670305	0.670339
LogReg one-hot	0.670311	0.000019	0.670294	0.670343
Global long LogReg	0.670288	0.000017	0.670261	0.670309

Источник: Repeated 5-fold OOF на seed 7, 13, 42, 123, 2026.




Рисунок 3. Mean $\pm$ standard deviation repeated OOF

Источник: Stage 2 repeated validation. Single-seed преимущество strong-only исчезает при усреднении.

Интерпретация. C=0.03 и C=1 статистически неразличимы. Полный ordinal логрег выбран не потому, что он заметно выше каждого конкурента, а потому, что сочетает лучший repeated mean, простоту и минимальный риск misspecification при неизвестном private distribution.

5.3. Калибровка и ансамбли

Cross-fit product-specific affine calibration снизила micro AUC с 0.670323 до 0.670278. Следовательно, базовый логрег уже формирует достаточно согласованную шкалу вероятностей. Лучший blend с one-hot моделью улучшил single-seed AUC приблизительно на 0.000005; blend с HGB — на 0.000003. Эти величины не имеют практической значимости.

6. Public leaderboard и риск выбора модели

Для оценки неопределенности использовалась повторная выборка подмножеств пользователей из OOF-прогнозов. Расчет не моделирует точную механику платформы, но показывает масштаб вариации AUC при фиксированной модели.

Public users	Пап	AUC std	p95 – p05
1 000	9 000	0.005659	0.018423
3 000	27 000	0.003147	0.010631

Public users	Пар	AUC std	p95 – p05
7 000	63 000	0.001973	0.006777
14 000	126 000	0.001405	0.004477
21 000	189 000	0.001074	0.003571

Источник: Bootstrap по OOF-прогнозам полного логрега.




Рисунок 4. Неопределенность public AUC в зависимости от размера выборки

Источник: Bootstrap по OOF. Даже при 14 000 пользователях диапазон p05–p95 примерно на три порядка выше лучших blend-дельт.

Если public содержит около 14 000 пользователей, диапазон p05–p95 составляет примерно 0.0045 AUC. При этом различия между лучшими кандидатами находятся около 0.000005–0.00004. Следовательно, ранжирование близких решений на public может определяться выборочным шумом, а многократные сабмиты превращают лидерборд в дополнительную валидационную выборку, на которую неизбежно происходит переобучение.

Правило отбора. Public-прирост без repeated OOF-прироста не является основанием для выбора main submission. Различия меньше 0.001–0.002 следует считать неопределенными, пока они не подтверждены независимой локальной валидацией.

7. Доступность hidden private

Локальная проверка структуры проекта не обнаружила test.csv, sample_submission, файлов public/private split или признаков hidden выборки. Файлы test_error.tsv являются журналами валидации CatBoost и не содержат тестовых объектов соревнования.

Объект проверки	Результат
Test features	Не находятся в репозитории; передаются контейнеру через --input-path во время оценки.
Private labels	Недоступны.
Split membership	Недоступна.
user_id leakage	Не выявлена: идентификаторы уникальны и выглядят случайными.
Docker interface	Читает входные признаки и записывает девять вероятностей; обратного канала нет.

Источник: Локальные файлы проекта и гип.ру трех решений.

Таким образом, подгонка непосредственно под private невозможна. Единственная корректная стратегия — строить модель, устойчивую к сэмплированию и умеренному distribution shift. Для данного генератора это дополнительно усиливает аргумент в пользу простой линейной модели.

8. Рекомендуемая стратегия соревнования

8.1. Основной сабмит

Компонент	Рекомендация
Модель	9 независимых LogisticRegression
Признаки	Все 8 исходных признаков
Масштабирование	StandardScaler
income_bucket	Ordinal integer
class_weight	None
C	1.0; допустимо 0.03 как эквивалент
Критерий выбора	Repeated OOF pooled/micro ROC-AUC
Финальное обучение	На всех 70 000 строках

8.2. Резервный controlled-risk сабмит

Если платформа позволяет выбрать два финальных решения, резервным кандидатом может быть strong-only логрег на income_bucket, digital_activity_score, has_child и is_salary_client. Он снижает зависимость от слабых признаков, но не имеет подтвержденного repeated OOF-преимущества. Blend с one-hot моделью не рекомендуется как основной: его локальная дельта слишком мала.

8.3. Процесс принятия решения

Шаг	Действие
1	Фиксировать validation protocol до просмотра нового public score.
2	Считать модель лучше только при устойчивом repeated OOF-приросте.
3	Логировать micro, macro и per-product AUC для каждого эксперимента.
4	Использовать public как sanity check, а не как функцию оптимизации.
5	Ограничить число leaderboard-driven итераций.

9. Ограничения исследования

Ограничение	Следствие для интерпретации
Не подтверждены официальная метрика и точная схема leaderboard.	Абсолютные значения local OOF нельзя напрямую отождествлять с итоговым рейтингом.
Неизвестны размеры public и private частей.	Bootstrap показывает диапазон риска для нескольких реалистичных объемов, а не точный прогноз shake-up.
Нет журнала реальных сабмитов.	Корреляция local OOF и public score не может быть оценена эмпирически.
Hidden test features и distribution shift недоступны.	Нельзя напрямую проверить гипотезы о сдвиге до запуска контейнера на платформе.
Полный повторный CatBoost search не проводился.	Вывод основан на существующем CatBoost OOF и проверке нелинейности через HGB.

Эти ограничения не меняют основной вывод о выборе семейства модели, но ограничивают уверенность в последних десятых и тысячных долях AUC.

10. Заключение

Исследование показало, что близкие результаты участников объясняются не обязательной подгонкой лидеров, а прежде всего структурой самой задачи: слабым и преимущественно линейным сигналом синтетического генератора, высокой балансировкой таргетов и малым пространством действительно полезных признаков.

Наиболее надежное решение — простая регуляризованная логистическая регрессия. Сложные преобразования, деревья, дополнительная калибровка и blends не дали устойчивого прироста. Различия между сильнейшими кандидатами значительно меньше ожидаемой вариации public AUC, поэтому оптимизация по лидерборду повышает риск ухудшения hidden private.

Финальная рекомендация. Публиковать полный ordinal logistic regression, выбранный по repeated OOF. Не пытаться восстанавливать private и не принимать микроулучшения public за доказательство качества.

Материалы и воспроизводимость

Материал	Локальный источник
Датасет	train_weRmhWx.csv
Первичный анализ	data_research_report.md
Stage 2	stage2_modeling_research.md
Линейное решение	logreg_solution/train.py и run.py
CatBoost baseline	catboost_solution/train.py и run.py

Все численные результаты в работе получены из локальных файлов проекта и OOF-прогонов. Промежуточные прогнозы не сохранялись; итоговые значения зафиксированы в двух markdown-отчетах.

Приложение А. Протокол воспроизводимости

Этап	Фиксируемый результат
1. Подготовка	Зафиксировать версии данных, набор признаков, целевые столбцы и результаты проверки утечек.
2. Валидация	Сохранить repeated OOF-разбиения и единый список seed для всех кандидатов.
3. Обучение	Записать гиперпараметры, время обучения и OOF-предсказания каждой модели.
4. Оценка	Рассчитать mean, standard deviation, worst seed и AUC по каждому таргету.
5. Отбор	Применить заранее заданный порог улучшения и ограничения по устойчивости.
6. Финализация	Обучить выбранную модель на полном train и сохранить журнал эксперимента.