БЛОК 0. Описательная статистика

Среднее, медиана, разброс

Видно: «найдите среднее, медиану, стандартное отклонение»
Код: `np.mean(x)`, `np.median(x)`, `np.std(x, ddof=1)`
Вывод: среднее $>$ медианы → хвост вправо (выбросы сверху)

Ловушка: `ddof=1` обязательно

Число интервалов гистограммы

Видно: «Стерджесс», «Фридман–Дьякони»
Формулы: $k = \lceil 1 + \log_2 n \rceil$; $h = \dfrac{2\,\mathrm{IQR}}{n^{1/3}}$
Код: `int(np.ceil(1+np.log2(n)))`; `np.arange(x.min(), x.max()+h, h)`

Ловушка: Стерджесс округлять вверх; n = `len(x)`

Выбросы по правилу IQR

Видно: «наблюдения за границами», «выбросы»
Формулы: $\mathrm{IQR} = Q_3 - Q_1$; границы $Q_1 - 1.5\,\mathrm{IQR}$ и $Q_3 + 1.5\,\mathrm{IQR}$
Код: `q1,q3=np.percentile(x,[25,75])`; `x[(x<lo)|(x>hi)]`

Ловушка: выброс — строго за границей; вывести ещё и количество

БЛОК 1. Распределения

Число успехов в n независимых опытах

Видно: «n заказов, каждый с вероятностью p»
Делаем: Биномиальное; $E = np$, $\mathrm{Var} = np(1-p)$
Код: `binom(n, p)`

Ловушка: «успех» — то, что считают в вопросе (опоздание, а не вовремя)

События за время, в среднем λ

Видно: «в среднем λ в минуту/час», «число обращений»
Делаем: Пуассон; $E = \mathrm{Var} = \lambda t$
Код: `poisson(mu=lam*t)`

Ловушка: t берём **из вопроса** (час = 60 минут)

Время между событиями / до k-го

Видно: «время до следующего», «до k-го обращения»
Делаем: Экспоненциальное; k-е событие — Гамма
Код: `expon(scale=1/lam)`; `gamma(a=k, scale=1/lam)`

Ловушка: `scale` = среднее время $= 1/\lambda$

Все законы: слова, код, E и Var

в условии, scipy	E	Var
один опыт: `bernoulli(p)`	p	$p(1-p)$
до первого успеха: `geom(p)`	$\frac{1}{p}$	$\frac{1-p}{p^2}$
без возвращения (M всего, n особых, N вытащили): `hypergeom(M,n,N)`	$\frac{Nn}{M}$	`.var()`
на $[a,b]$ равновероятно: `uniform(loc=a, scale=b-a)`	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
время до события: `expon(scale=1/lam)`	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
время до k-го: `gamma(a=k, scale=1/lam)`	$\frac{k}{\lambda}$	$\frac{k}{\lambda^2}$
нормально: `norm(loc=mu, scale=sigma)`	μ	σ^2

Ловушка: в `norm` второй параметр σ, не σ^2; для дискретных `pmf`, для непрерывных `pdf` — плотность, не вероятность

Вероятность: слова → метод

ровно k	`pmf(k)`	не более k	`cdf(k)`
менее k	`cdf(k-1)`	более k	`sf(k)`
не менее, хотя бы k	`sf(k-1)`	x по вероятности	`ppf(q)`, `isf(q)`

Ловушка: у непрерывных -1 не нужен; $P(a \le X \le b) = \mathrm{cdf}(b) - \mathrm{cdf}(a-1)$; E, σ — `mean()`, `std()`

Прибыль, штраф, константа в задаче

Видно: «каждое обращение приносит 240 ₽», «штраф за каждое»
Делаем: $E[aX+b] = aE[X]+b$; $\mathrm{Var}(aX+b) = a^2\mathrm{Var}(X)$

Ловушка: константа в Var — в квадрате; ответ именно на последний вопрос (прибыль ≠ выручка)

Сумма n величин, «с помощью ЦПТ»

Делаем: $E = n\mu$, $\mathrm{Var} = n\sigma^2$, $T \approx N(E, \sqrt{\mathrm{Var}})$
Код: `norm(E, sd).sf(nopor)`, `sd=np.sqrt(Var)`
Среднее: $\bar{X} \approx N(\mu,\ \sigma/\sqrt{n})$; $\mathrm{Bin} \approx N(np, \sqrt{np(1-p)})$

Ловушка: Var суммы — $n\sigma^2$, а не n^2; в `scale` — σ

Свой закон (таблица «значение → вероятность»)

Делаем: $E = \sum x\,p$, $\mathrm{Var} = \sum x^2 p - E^2$
Код: `E=(xs*ps).sum()`, `V=(xs**2*ps).sum()-E**2`

БЛОК 3. Проверка гипотез и ДИ

Какой критерий выбрать

что сравниваем	критерий	SE
среднее, σ дана	Z	$\sigma/\sqrt{n}$
среднее, σ нет	t, $df = n-1$	$s/\sqrt{n}$
доля с числом	Z	$\sqrt{p_0(1-p_0)/n}$
две доли (A/B)	Z, объединённая доля	см. карточку A/B
два средних	`ttest_ind(a,b,equal_var=False)`; парные `ttest_rel`	

Проверить гипотезу о среднем

Шаги: $H_0, H_1 \to z = \dfrac{\bar{x} - \mu_0}{SE}$ → p-value → сравнить с α → вывод словами

H_1	Z	t
$\neq$	`2*norm.sf(abs(z))`	`2*t.sf(abs(t),df)`
$>$	`norm.sf(z)`	`t.sf(t,df)`
$<$	`norm.cdf(z)`	`t.cdf(t,df)`

Код: `stats.ttest_1samp(x, mu0, alternative="greater")` (`"less"`, `"two-sided"`)

Вывод: $p < \alpha$ → отвергаем H_0; $p \ge \alpha$ → **не** отвергаем (не «равны»)

Доверительный интервал

σ дана	$\bar{x} \pm z\frac{\sigma}{\sqrt{n}}$, `norm.interval(.95, loc=xbar, scale=se)`
σ нет	$\bar{x} \pm t_{n-1}\frac{s}{\sqrt{n}}$, `t.interval(.95, df=n-1, loc=xbar, scale=se)`
доля	$\hat{p} \pm z\sqrt{\hat{p}(1-\hat{p})/n}$ (своя доля!)

z: 90% — 1.645; 95% — 1.960; 99% — 2.576
(односторонний: 1.282; 1.645; 2.326)

Связь: μ_0 вне 95%-ДИ ⇔ двусторонний тест отвергает H_0 на 5%

Две доли (A/B-тест)

Конверсии: $\hat{p}_A = \frac{k_A}{n_A}$, $\hat{p}_B = \frac{k_B}{n_B}$
Эффект: п.п. $(\hat{p}_B - \hat{p}_A)\cdot 100$; относит. $\left(\frac{\hat{p}_B}{\hat{p}_A} - 1\right)\cdot 100\%$
Тест: $\hat{p} = \frac{k_A+k_B}{n_A+n_B}$; $SE = \sqrt{\hat{p}(1-\hat{p})\left(\frac{1}{n_A}+\frac{1}{n_B}\right)}$; $z = \frac{\hat{p}_B - \hat{p}_A}{SE}$

Ловушка: объединённая доля только в SE теста; в ДИ — своя; знак эффекта важен

БЛОК 2. Точечные оценки

Проверить несмещённость, найти смещение

Делаем: $E[\hat\theta]-\theta$; несмещена, если $=0$. $\mathrm{MSE}=\mathrm{Var}+\mathrm{bias}^2$

Линейная: $\sum w_iX_i$: $E=\mu\sum w_i$, $\mathrm{Var}=\sigma^2\sum w_i^2$ (несмещена при $\sum w_i=1$)

Дисперсия: $\frac{1}{n-1}\sum(x_i-\bar x)^2$ несмещённая, $\frac{1}{n}\sum$ смещена

Ловушка: константа в Var — в квадрате

ОМП: найти оценку параметра

Шаги: $L=\prod P(x_i)\to\ln L\to\frac{d\ln L}{d\theta}=0\to\hat\theta\to\frac{d^2\ln L}{d\theta^2}<0$

	$\ln L$	ОМП
Pois(λ)	$S\ln\lambda-n\lambda$	$\bar x$
Exp(λ)	$n\ln\lambda-\lambda S$	$\frac{n}{S}=\frac{1}{\bar x}$
Bern(p)	$S\ln p+(n-S)\ln(1-p)$	$\bar x$
Geom(p)	$n\ln p+(S-n)\ln(1-p)$	$\frac{n}{S}$
Bin(m,p)	$S\ln p+(nm-S)\ln(1-p)$	$\frac{S}{nm}$
N, σ дана	$-\frac{\sum(x_i-\mu)^2}{2\sigma^2}$	$\bar x$
N, обе неизв.	$-\frac{n}{2}\ln\sigma^2-\frac{\sum(x_i-\mu)^2}{2\sigma^2}$	$\hat\mu=\bar x$, $\hat\sigma^2=\frac{1}{n}\sum(x_i-\bar x)^2$
$U(0,\theta)$	$L=\theta^{-n}$, $\theta\ge\max$	$\max x_i$

Ловушка: L — произведение, сумма только у $\ln L$; $S=\sum x_i$; константы без θ отбрасываем

ОМП своего закона (счётчики)

Делаем: $L=\prod_k P(k)^{n_k}$, где n_k — сколько раз встретилось k

Код: `counts=np.bincount(x)`; `sp.expand_log(sp.log(L), force=True)`

ОМП в sympy

`lam=sp.symbols("lam", positive=True)` `lnL=S*sp.log(lam)-n*lam`; `d1=sp.diff(lnL, lam)` `sol=sp.solve(sp.Eq(d1,0), lam)` — **список**, берём `sol[0]` `sp.diff(lnL,lam,2).subs(lam, sol[0])` $<0\to$ максимум

Ловушка: экспонента `sp.exp(...)`; `.subs(переменная, значение)`

Метод моментов

Делаем: $E[X]=g(\theta)$ приравнять к $\bar x$, выразить θ

Совпадает с ОМП: Bern, Pois, N; у $U(0,\theta)$ — нет ($2\bar x$ против $\max$)

Информация Фишера, граница Рао–Крамера, эффективность

Шаги: $\ln f$ (**одно** наблюдение) $\to\frac{\partial^2}{\partial\theta^2}\to I_1=-E[\cdot]\to I_n=nI_1\to$ граница $\frac{1}{I_n}$

	I_1	граница
Bern	$\frac{1}{p(1-p)}$	$\frac{p(1-p)}{n}$
Pois	$\frac{1}{\lambda}$	$\frac{\lambda}{n}$
Exp	$\frac{1}{\lambda^2}$	$\frac{\lambda^2}{n}$
N, σ дана	$\frac{1}{\sigma^2}$	$\frac{\sigma^2}{n}$

Для $g(\theta)$: $\frac{g'(\theta)^2}{I_n}$; **смещённая** с $b(\theta)$: $\frac{(1+b'(\theta))^2}{I_n}$

Эффективна: несмещена и $\mathrm{Var}(\hat\theta)=\frac{1}{I_n}$ ($\bar x$ — у Bern, Pois, N)

Ловушка: производная по θ, не по x; если остался x — подставить $E[X]$; для $U(0,\theta)$ не работает

Особые случаи оценок

Exp: $E\left[\frac{1}{\bar X}\right]=\frac{n\lambda}{n-1}\to$ смещение $+\frac{\lambda}{n-1}$; несмещённая $\frac{n-1}{S}$

$U(0,\theta)$: $E[\max]=\frac{n}{n+1}\theta$ (смещена); $\frac{n+1}{n}\max$ несмещена

MSE для $U(0,\theta)$: $2\bar x$: $\frac{\theta^2}{3n}$; $\max$: $\frac{2\theta^2}{(n+1)(n+2)}$; $\frac{n+1}{n}\max$: $\frac{\theta^2}{n(n+2)}$ (лучшая)

Состоятельность: $\mathrm{bias}\to0$ и $\mathrm{Var}\to0$

БЛОК 3 (планирование)

Размер выборки и MDE (две группы, доли)

z: `norm.ppf(.975)+norm.ppf(.8)` $=1.96+0.84=2.80$

n **на группу:** $\frac{2z^2p(1-p)}{\delta^2}$ — **вверх** `int(np.ceil(...))`; всего $2n$

MDE: $\sqrt{\frac{2z^2p(1-p)}{n}}$ (п.п. $=\mathrm{MDE}\cdot100$)

Среднее: одна выборка $n=\left(\frac{z\sigma}{\delta}\right)^2$; две группы $2\left(\frac{z\sigma}{\delta}\right)^2$

Зависимости: δ вдвое меньше $\to$ n в 4 раза больше; n в 4 раза больше $\to$ MDE вдвое меньше

Ошибки и мощность

I рода (α) — ложная тревога; II рода (β); мощность $=1-\beta$. Наблюдаемый эффект $<$ MDE $\Rightarrow$ мощности не хватило.

Как писать вывод

z (или t) $=\ldots$, $p=\ldots$ ($<$ / $\ge$) $\alpha\Rightarrow H_0$ (отвергаем / не отвергаем): что изменилось, в какую сторону, на сколько (п.п. или %).

НЕДЕЛЯ 9. Множественные сравнения

Проверить сплит-систему

A/A-тест: группы без воздействия, значимых различий быть не должно

Проверка: конверсия по децилям id и по последней цифре; деление по медиане и чётности id плохо

Хеш: `int(hashlib.md5((str(id)+salt).encode()).hexdigest(),16) % k`

Ловушка: сначала очистить выборку от неподходящих (уже ездили)

Много групп: поправки и ANOVA

Пар из k групп: $\binom{k}{2}$; $\mathrm{FWER}=1-(1-\alpha)^m$

Бонферрони: порог α/m (4 группы: 6 пар, $0.05/6\approx0.0083$)

Холм: p по возрастанию, k-е сравнить с $\frac{\alpha}{m-k}$, стоп на первом непрошедшем

ANOVA: `stats.f_oneway(*groups)`; $F<1$ — различий нет; не говорит, какая пара

ЧЕК-ЛИСТ ЛОВУШЕК

- ответ на **последний** вопрос; числа в коде = числа в условии
- `ddof=1`; Стерджесс и n — вверх; `scale=1/λ`; `mu=λ·t`; `norm`: σ
- «не менее» $\to$ `sf(k-1)`; «более» $\to$ `sf(k)`
- p-value двусторонний: $\times2$ и `abs`; H_1 :$>\to$ `sf`; σ нет $\to$ t
- ОМП: проверить $d^2<0$; эффективность = несмещённость и $\mathrm{Var}=1/I_n$
- «не отвергаем» ≠ «равны»; вывод — словами с цифрами